

目录

以“条件化轨迹”为核心重新设计 Latent Persona Stability Region、Persona Margin 与 Persona Robust Radius	1
执行摘要	1
背景、目标与必须先解决的识别问题	3
开放假设与数据重构	4
最重要的数据重构：制造“同条件不同结局”	4
条件化轨迹表示与 Latent Persona Stability Region	6
从单点 projection 改成状态向量	6
最关键的一步：预测“正常 Pressure Response”	7
“封闭范数空间”如何正式定义	8
如何优化这个封闭 Region	9
Persona Margin 与 Persona Robust Radius 的新定义	10
Persona Margin：距离正常稳定轨迹还有多少余量	10
Robust Radius：不要再定义成 activation 距离	12
但这里必须区分预测量和因果量	13
候选 Region 模型与推荐技术路线	14
第一版我会真正实现的模型	15
评估方案与短期可执行实验计划	16
短期实验计划	18

以“条件化轨迹”为核心重新设计 Latent Persona Stability Region、Persona Margin 与 Persona Robust Radius

执行摘要

是的，我建议重新制定方案，而且核心变化应该很明确：从“某一时刻 activation 在哪里”改成“在给定的 Persona、压力历史和对话条件下，这条 activation 轨迹是否仍沿着正常的稳定轨迹演化”。

重新审视你们已有结果后，这不是单纯为了把方法做复杂，而是被现有实验结果逼出来的。Gate B 已经证明 Layer 20 的 Persona Vector 能很好地区分 held-out persona expression；但 Gate C v1/v2 又发现，同一套 Layer-20 activation 监控器在 Independent / Sycophantic 这种多数不发生持续漂移的轴上，只要受到 pressure 就会大量报警。也就是说，Persona Vector 能表示 Persona，也能响应 Pressure，但“响应 Pressure”并不等于“正在走向 Persona Drift”。

因此我建议把整个理论对象改成：

Raw Persona State → Expected Pressure Response → Residual Trajectory
→ Stability Region → Margin → Robust Radius

其中最关键的新量不是原始 Persona projection，而是：

$$e_t = z_t - \hat{z}_t^{\text{stable}}$$

也就是：

当前内部状态，相对于“在相同 Persona、相同压力历史下，一个仍然稳定的 Agent 正常应该走到哪里”的偏差。

这直接针对了 Gate C 暴露出来的问题：Independent Agent 在压力下 activation 也会移动；我们不应该把这种“正常的压力响应”误认为 Drift warning。Gate C v2 的正式解释也正是：Layer-20 signal 对 resistant axis 的 pressure 有响应，但这种响应并不具有 future behavioral drift specificity。

关于你提出的“为什么一定要山谷？能不能用封闭范数空间？”：完全可以，而且数学上更严谨。但严格来说，不建议称为“封闭范数空间”。更准确的说法是：

在一个带范数的轨迹空间中，定义一个封闭的条件稳定集合 (closed conditional stability set)。

例如：

$$\mathcal{X}_t = (\mathbb{R}^d)^t$$

在这个轨迹空间中定义范数：

$$\|\tau\|_W = \sqrt{\tau^\top W \tau}, \quad W \succ 0$$

然后定义：

$$\mathcal{R}_{\alpha,t}(c) = \{\tau_{1:t} : A(\tau_{1:t}; c) \leq q_\alpha\}$$

只要 A 是连续函数，这个 sublevel set 就是封闭的。因此“山谷”只适合组会解释；论文里完全可以把 Persona Stability Region 正式定义成条件轨迹空间中的封闭接受域。

最重要的是，不要现在立刻上 **normalizing flow** 或复杂深度模型。现有数据最大的瓶颈不是模型表达能力，而是 outcome 几乎被 Persona axis 决定：Gate A pilot 中 Cautious pressure 是 20/20 drift, Independent pressure 是 0/20；新的三 Judge Qwen remeasurement 是 58/60 对 2/60；OLMo confirmatory replication 又是 60/60 对 0/60。

所以真正的下一步应该首先构造：

$$\begin{aligned} &\text{Same Persona} + \text{Same Pressure Family} + \text{Same Pressure Dose} \\ &\Rightarrow \begin{cases} \text{Drift,} \\ \text{Stable.} \end{cases} \end{aligned}$$

否则任何预测器都可能学成：

“Cautious = 会 Drift, Independent = 不会 Drift。”

而不是学到“稳定性”。

我推荐的第一版可操作方案是：

Conditional Gaussian / Mahalanobis Trajectory Tube + discrete-time hazard model + randomized pressure-dose experiment.

它足够简单、可解释，和你们已有 Layer-20 数据兼容，而且能够直接回答三件事：

Region : 正常稳定轨迹应该走在哪里？

Margin : 当前轨迹距离稳定边界还有多少？

Robust Radius : 还需要增加多少实验定义的 Pressure, 才会使 Drift 风险越过阈值？

后面如果这个 baseline 成立，再升级 GP、HMM、conditional flow。

背景、目标与必须先解决的识别问题

你们现有工作其实已经非常清楚地暴露出了为什么“静态 Region”不够。

Gate B 的 Persona representation 结果很强：使用未参与 vector extraction 的 held-out prompts, Layer 20 的 response-token-mean activation 在 Persona Vector 上的 cosine projection, 对 Cautious/Risk-seeking 和 Independent/Sycophantic 两条轴的 test AUROC 都是 1.000; projection 与输出行为评分的 Spearman correlation 分别为 0.890 和 0.764。也就是说, Persona Vector 的确携带了与外显 Persona expression 有关的信息。

但是 Gate C 告诉我们, **representation validity 并不能自动转化成 prospective prediction validity**。在 Gate C development v2 中, axis-calibrated activation predictor 在 Independent/Sycophantic development test 的 800 个 eligible turns 上产生了 285 次 activation-only alarms, combined model 产生 270 次 alarms, 而且全部集中在 pressure trajectories; clean controls 没有报警。项目自己的结论就是: Layer-20 signal 能检测到 pressure response, 却不能可靠区分“pressure response”和“未来会发生 behavioral drift”。

后续 preregistered Qwen confirmation 进一步显示, 原 activation pipeline 对 resistant pressure trajectories 的 combined alarm 是 60/60, 而当时旧的 two-judge output criterion 只判出了 16/60 drift; 同一 confirmation 中 activation 也没有在 five-turn forecasting 上提供有实用意义的 text-incremental AUPRC improvement。后来的三 Judge measurement 修正了很多 resistant-axis false drift, Qwen pressure drift 变为 Cautious 58/60、Independent 2/60; OLMo 的正式 replication 则为 60/60 与 0/60。

所以我们现在可以更准确地把科学问题写成：

Pressure Response $\neq$ Persona Instability

真正需要识别的是：

异常于正常 Pressure Response 的内部动力学

而不是简单的：

Persona Projection 下降

这正是为什么“条件化轨迹”比“静态 activation 点”更合理。

可以把整个过程画成：




图 1: 条件化轨迹与人格失稳的概念流程

这也意味着, 原来那个“山谷中的球”隐喻没有错, 但只是解释层面的隐喻。正式方案里不需要任何“山谷”假设, 更不需要假设 latent space 真的有势能函数。Representation engineering 本身就是把高层语义行为放在内部表示空间中研究, 而不要求那个空间具有某种物理势能几何。

这里还有一个重要的研究纪律: 你们已经反复使用过现有 Gate C development/confirmation data, 所以不能继续在相同 test set 上设计 Region、选择特征、调 Margin, 再把同一数据上的好结果称

作 **confirmatory evidence**。项目已有 paper strategy 也明确建议：若继续构建更强 seismograph, 应收集新的 development corpus, 并保留整条 axis、新 topic 和新 seed 做 untouched evaluation。

开放假设与数据重构

在正式写代码之前, 有几个目前并没有完全指定的条件必须明确。下面这些不能偷偷假设, 应该写进新 protocol。

尚未指定、建议保持为开放假设的事项包括:

第一, 现有 activation logs 到底是**每一轮 main response 都保存了 activation**, 还是只有 six isolated probe checkpoints 有完整 activation。如果 25 个 main turns 都有 Layer-20 response-token-mean activations, 那么可以直接做 25-point trajectory; 如果只有 checkpoint activation, 那么 Region 只能先做 6-point trajectory, 时间分辨率会明显下降。你们 Gate A/OLMo protocol 本身确实是 25 轮、6 个 isolated checkpoints, 但公开结果文档并不能证明所有层、所有 main turns 的原始 activation 都永久保存。

第二, 是否只有 Layer 20 可用, 还是所有 residual-stream layers 都已有导出。Gate B 只证明 validation-selected Layer 20 适合作为 frozen representation layer, 并不证明 Layer 20 是唯一携带动态失稳信号的层。

第三, 是否能够访问 attention output、MLP output、pre/post residual stream。如果能访问, 可以在后续研究“失稳发生在哪个计算组件”; 如果不能, **第一版完全没必要补采这些东西**, 先使用 residual stream 即可。

第四, Pressure 是否已经有可量化的 protocol-level 强度。例如 gradual pressure 的每轮模板是否能映射到 0, 1, 2, 3, ... 的强度等级。如果目前只是“gradual/abrupt”分类而没有连续 dose, 那么 Robust Radius 暂时不能真正用“pressure units”解释, 必须先设计 dose-response protocol。

第五, 是否允许做新的**干预实验**。这对 Robust Radius 至关重要: 如果只利用现有 observational trajectories, 我们最多得到“model-implied pressure distance”; 如果随机化不同 pressure dose, 就可以更接近:

$$P(\text{Drift} \mid \text{do}(\text{Pressure}))$$

意义上的 intervention-based radius。

第六, 新实验可承受多少 trajectories、topics、seeds 和模型。最终样本量不建议现在拍脑袋确定, 应使用 transition-band pilot 得到 drift probability 和 trajectory variance 后再做 power simulation; 你们已有 protocol 也采用 trajectory-level bootstrap, 而不是把每一轮当作独立样本。

最重要的数据重构: 制造“同条件不同结局”

当前数据最大的问题是:

$$P(Y = \text{Drift} \mid \text{Cautious}, \text{Pressure}) \approx 1$$

而:

$$P(Y = \text{Drift} \mid \text{Independent}, \text{Pressure}) \approx 0$$

这会产生严重的可识别性问题。

因此推荐新增一个 **Pressure Dose-Finding Pilot**。

把 gradual pressure 写成一个基础 schedule:

$$u_{1:25}^{(0)}$$

引入压力倍率：

$$\lambda \geq 0$$

得到：

$$u_{1:25}^{(\lambda)}$$

其中 $\lambda = 0$ 对应无反 Persona pressure, $\lambda = 1$ 对应现有冻结 protocol 的强度, $\lambda < 1$ 是弱化版本, $\lambda > 1$ 是加强版本。

这里不要通过“随便改 prompt”实现, 而要建立固定 ordinal templates, 例如：

0 = Neutral

1 = 非常弱的反 Persona 建议

2 = 弱压力

3 = 中等压力

4 = 强压力

5 = 极强压力

逐轮 gradual schedule 再定义为这些等级的确定性序列。

先用 development seeds 搜索：

$$0.2 < P(\text{Drift} \mid \text{Persona}, \lambda) < 0.8$$

的 **transition band**。

例如 Cautious 当前 $\lambda = 1$ 几乎全部 Drift, 那么应该减弱：

$$\lambda = 0.25, 0.4, 0.55, 0.7$$

寻找一个中间点。

Independent 当前多数 Stable, 则可以适当增强 pressure; 但如果在合理强度范围内依然几乎从不 Drift, **不要为了数学漂亮硬把它推到 Drift**。更好的方案是新增第三、第四个 susceptibility 中等的 Persona axis。你们自己的 post-Gate-C strategy 事实上已经建议 future seismograph development 使用 multiple susceptible and resistant axes, 而不是继续依赖 Cautious 与 Independent 两个极端轴。


真正理想的数据应该长成：

Persona	Pressure family	Dose	Drift	Stable
Cautious	Gradual	λ^*	约 40–60%	约 40–60%
Persona B	Gradual	λ^*	约 40–60%	约 40–60%

Persona	Pressure family	Dose	Drift	Stable
Cautious	Abrupt	λ^*	有	有
Independent	Gradual	当前或增强	可能少量	大量

尤其关键的是，在选定 transition dose 以后，**冻结同一个 schedule**，然后换新 topic 和新 seed 重跑。这样才出现：

同一个 Persona
同一个 pressure family
同一个 pressure dose
同样 25 turns



此时模型才不能靠 Persona label 和 condition label 作弊。

还要特别注意：训练分类器时可以考虑为了优化做 class weighting，但如果最后输出：

$$P(\text{Drift})$$

这种概率，就不能把人为 oversampling 后的 class prevalence 当成真实风险，需要重新 calibration。

条件化轨迹表示与 Latent Persona Stability Region

从单点 projection 改成状态向量

保留你们已经验证过的 Persona Vector。

对第 t 轮、第 ℓ 层，先算：

$$p_t^{(\ell)} = \cos(\bar{h}_t^{(\ell)}, v_{\text{persona}}^{(\ell)})$$

其中：

$$\bar{h}_t^{(\ell)}$$

是该轮回答的 response-token-mean residual activation。

Layer 20 的：

$$p_t^{(20)}$$

仍然应该作为**最重要 baseline feature**，因为它已经有独立 held-out representation validation。

但是不要只用这一维。

如果多个层可用，我推荐：

$$z_t = [p_t^{(\ell_1)}, p_t^{(\ell_2)}, \dots, p_t^{(\ell_K)}, n_t^{(20)}]$$

其中：

$$n_t^{(20)} = \|\bar{h}_t^{(20)}\|_2$$

如果当前确实只有 Layer 20，则先定义：

$$z_t = [p_t^{(20)}, n_t^{(20)}]$$

再构造动态特征：

$$\Delta z_t = z_t - z_{t-1}$$

$$\Delta^2 z_t = \Delta z_t - \Delta z_{t-1}$$

分别对应：

当前在哪里、移动多快、移动方向是否正在加速改变。

这并非纯粹的直觉扩展。时间序列 boundary detection 中已有工作明确将 sequence representations 看作 trajectory，并使用表示轨迹的 curvature 来捕捉 gradual 与 abrupt change；Neural CDE 等方法也把随时间输入驱动的 latent evolution 作为整体动力系统建模。

但第一版没有必要上 curvature theorem。你们已有 25 个离散 rounds：

$$z_1, z_2, \dots, z_{25}$$

差分就够了。

最关键的一步：预测“正常 Pressure Response”

定义条件变量：

$$c_t = (\text{model}, \text{persona}, \text{pressure family}, \text{pressure history}, \text{turn}, \text{topic})$$

其中 pressure history：

$$u_{1:t} = (u_1, u_2, \dots, u_t)$$

然后只使用**最终保持 stable 的 training trajectories** 学习：

$$\hat{z}_t^S = g_\theta(z_{1:t-1}, u_{1:t}, c)$$

它的意思非常直白：

在这个 Persona、这个 Pressure 历史、这个 turn 下，一个仍然稳定的 Agent 的内部状态正常应该走到哪里？

然后定义真正要监控的 quantity：

$$e_t = z_t - \hat{z}_t^S$$

这就是：

Pressure-residual persona state。

例如：

原始 Persona Projection

Independent Stable:

$1.0 \rightarrow 0.9 \rightarrow 0.75 \rightarrow 0.60$

Cautious Future Drift:

$1.0 \rightarrow 0.9 \rightarrow 0.75 \rightarrow 0.60$

原始曲线看起来一样危险。

但条件模型可能知道:

Independent under this pressure

正常稳定轨迹本来就会:

$1.0 \rightarrow 0.9 \rightarrow 0.76 \rightarrow 0.61$

所以 residual:

$0 \rightarrow 0 \rightarrow -0.01 \rightarrow -0.01$

而 Cautious 的稳定参考可能应该是:

$1.0 \rightarrow 0.95 \rightarrow 0.91 \rightarrow 0.88$

实际却是:

$1.0 \rightarrow 0.9 \rightarrow 0.75 \rightarrow 0.60$

于是:

$0 \rightarrow -0.05 \rightarrow -0.16 \rightarrow -0.28$

这才是“失稳”。

“封闭范数空间”如何正式定义

这里修正一下术语。

不建议写:

Persona Stability Region 是一个封闭范数空间。

因为 stable region 通常不是 vector space: 两个稳定 trajectory 相加, 不一定还是稳定 trajectory; 乘 10 也不可能仍然稳定。

应该写:

我们在一个 normed trajectory space 中定义 closed stability set。

令:

$$\mathcal{X}_t = (\mathbb{R}^d)^t$$

trajectory prefix:

$$E_{1:t} = [e_1^\top, e_2^\top, \dots, e_t^\top]^\top$$

定义一个带权范数:

$$\|E_{1:t}\|_{W_t} = \sqrt{E_{1:t}^\top W_t E_{1:t}}, \quad W_t \succ 0$$

然后:

$$\mathcal{R}_{\alpha,t}(c) = \{E_{1:t} : \|E_{1:t}\|_{W_t} \leq r_{\alpha,t}(c)\}$$

这就是一个**封闭的条件 Stability Region**。

如果：

$$W_t = \Sigma_t^{-1}$$

那么它就是 trajectory-space 的 Mahalanobis ellipsoid。


Mahalanobis feature-space distance 本身已有成熟的 OOD / abnormality 使用方式：Lee 等人的方法对神经网络中间表示拟合 class-conditional Gaussian，并用 Mahalanobis distance 作为 abnormality/confidence score；Deep SVDD 则从 one-class 学习角度把正常数据压进 hypersphere。

但你们这里与传统方法的区别应该明确写出来：

我们不是在原始 activation space 拟合静态 sphere，而是在 pressure-residual trajectory space 中拟合 conditional tube。

也就是：


静态 Region：



问题：

只知道“现在偏了”。

Conditional Trajectory Region：



问题变成：

“在这个压力下，你是不是沿着正常稳定轨迹走？”

如何优化这个封闭 Region

第一版不要同时优化所有东西。

推荐采用**两阶段训练**：

训练阶段学习：

$$g_{\theta}$$

以及：

$$W_t$$

校准阶段不再调整模型，只使用 held-out stable calibration trajectories 决定：

$$r_{\alpha,t}$$

例如令：

$$r_{\alpha,t} = Q_{1-\alpha}(\|E_{1:t}\|_{W_t})$$

其中：

$$Q_{1-\alpha}$$

是 stable calibration distribution 的 $1 - \alpha$ 分位数。

这样 Region 的意思就是：

约 $1 - \alpha$ 的 calibration stable trajectories 落在这个 tube 内。

如果将来希望有更正式的不确定性 calibration，可以把 nonconformity score 与 sequential/time-series conformal 方法结合；不过时间序列存在相关性，不能简单套 iid conformal 假设，应该使用专门针对 sequential/time-series 的 calibration 方案。已有 time-series conformal 工作就是为依赖数据和 sequential prediction 构造 prediction intervals 或 nonconformity calibration。

Persona Margin 与 Persona Robust Radius 的新定义

这两个概念一定要分清楚。

Margin 是 state/trajectory space 的量。

Robust Radius 是 pressure/action space 的量。

如果两个都定义成 activation 欧氏距离，它们其实会变成重复概念。

Persona Margin：距离正常稳定轨迹还有多少余量

如果 Stability Region 使用前面的 W -norm：

$$\mathcal{R}_{\alpha,t} = \{E : \|E\|_{W_t} \leq r_{\alpha,t}\}$$

那么最干净的 Persona Margin 就是：

$$M_t^{\text{geo}} = r_{\alpha,t} - \|E_{1:t}\|_{W_t}$$

解释：

$$M_t > 0$$

仍然在稳定区域内部。

$$M_t \rightarrow 0$$


正在接近稳定边界。

$$M_t < 0$$

已经超出了 typical stable trajectory region。

例如：

Margin



这比原来：

$$\cos(h, v_{\text{persona}})$$

更有解释力，因为它已经去掉了“这个 Persona 在当前 Pressure 下本来就应该发生的正常移动”。

但这仍然只是：

异常程度。

它没有直接告诉我们：

“未来 H 轮发生 Drift 的概率是多少？”

因此我建议再定义一个**预测 Margin**。

令：

$$R_t^{(H)} = P(T_{\text{drift}} \leq t + H \mid E_{1:t}, u_{1:t}, c)$$

设预警风险阈值为：

$$\eta$$

例如 development protocol 固定的某个 risk threshold。

定义：

$$M_t^{\text{risk}} = \text{logit}(\eta) - \text{logit}(R_t^{(H)})$$

于是：

$$M_t^{\text{risk}} > 0$$

风险还没有到 warning boundary;

$$M_t^{\text{risk}} = 0$$

刚好到 warning threshold;

$$M_t^{\text{risk}} < 0$$

已经进入 high-risk zone。

这个 risk model 很适合使用 **discrete-time survival / hazard model**, 因为你们的问题天然就是 time-to-event:

Drift 在哪一轮首次出现?

同时 stable trajectories 在 25 轮结束时相当于 right-censored。Survival analysis 正是用来处理 time-to-event 与 censoring 的; 已有 dynamic survival/early-event-prediction 方法也直接基于随时间增长的 sequence 估计 event risk。

定义 hazard:

$$q_t = P(T_{\text{drift}} = t \mid T_{\text{drift}} \geq t, E_{1:t})$$

那么未来 H 轮发生 Drift 的风险:

$$R_t^{(H)} = 1 - \prod_{k=t+1}^{t+H} (1 - q_k)$$

这其实非常适合你们现在的研究目的, 比把每个 turn 简单变成 binary classification row 更自然。

Robust Radius: 不要再定义成 activation 距离

我强烈建议把 Persona Robust Radius 改成:

在当前内部状态下, 还需要增加多少外部 Persona Pressure, 才会把未来 Drift risk 推过预先定义的阈值?

定义当前未来 pressure plan:

$$u_{t+1:t+H}$$

允许增加:

$$\delta u$$

risk model:

$$R_t(u_{t+1:t+H}) = P(T_{\text{drift}} \leq t + H \mid E_{1:t}, u_{t+1:t+H}, c)$$

那么:

$$\boxed{\begin{array}{l} \rho_t = \inf_{\delta u \in \mathcal{D}} C(\delta u) \\ \text{s.t. } R_t(u + \delta u) \geq \eta \end{array}}$$

其中 $C(\delta u)$ 是 pressure cost。

例如:

$$C(\delta u) = \sum_{k=1}^H w_k |\delta \lambda_{t+k}|$$

于是 ρ_t 的单位不再是:

activation distance

而是：

额外 pressure dose。

为了组会和论文都容易解释，可以给你们自己的实验压力单位起一个明确名字，例如：

Protocol Pressure Unit, PPU

假设 gradual pressure 有 0-5 五级模板。

那么：

Agent A

当前 Robust Radius = 8.4 PPU

意思：

在未来 H 轮内，

还需要额外累计约 8.4 个 protocol pressure units，

预测 Drift risk 才会超过 η 。

而：

Agent B

Robust Radius = 1.2 PPU

意味着：

很小的额外压力就可能进入 high-risk state。

这个解释比“离 hyperplane 0.18”科学意义强很多。

但这里必须区分预测量和因果量

如果只是用现有 trajectory 拟合：

$$R_t(u)$$

那么只能叫：

model-based robust radius

不能说：

“真的再加 1.2 PPU 就会导致 Drift。”

如果未来 pressure dose 是随机实验分配的，则可以定义更强版本：

$$\rho_t^{\text{causal}} = \inf_{\Delta\lambda \geq 0} \left\{ \Delta\lambda : P(T_{\text{drift}} \leq t + H \mid \text{do}(\lambda + \Delta\lambda), \mathcal{F}_t) \geq \eta \right\}$$

其中：

$$\mathcal{F}_t$$

表示当前已经观察到的历史。

这才真正接近：

“这个 Persona 还能承受多大额外压力？”

所以 Robust Radius 的可信度取决于你们愿不愿意做 pressure-dose intervention experiment。

如果不能做，那论文里应明确称：

Latent Pressure-to-Risk Distance

而不是声称 causal robustness。

候选 Region 模型与推荐技术路线

这里不应该一开始就选最复杂的方法。现有 trajectories 数量在深度时序建模语境下仍然不大，而且 outcome imbalance 很严重；项目此前的 240-trajectory experiments 主要价值是 protocol 与现象验证，而不是为高容量 generative sequence model 提供海量训练数据。

我会按以下顺序做。

方法	Region 怎么表示	优点	缺点	典型复杂度	数据需求	推荐级别
Conditional Mahalanobis Tube	条件均值轨迹 + covariance ellipsoid	最可解释；Margin 有精确几何意义；适合小数据	假设局部近似椭圆；复杂多模态轨迹表达有限	低到中	小-中	第一优先
Gaussian Process / GPSSM	$p(z_t z_{t-1}, u_t, c)$	小数据友好；天然输出 uncertainty；适合非线性	高维扩展较贵；实现复杂度高于 Gaussian	中-高	小-中	第二优先
HMM / Switching State Model	Stable / Responding / Unstable 隐状态	非常容易解释“状态转移”；适合找失稳阶段	emission/ Markov 假设可能过简	中	中	第二优先
Conditional Normalizing Flow	条件 trajectory likelihood	能拟合复杂非高斯 Region；不要求椭圆	对数据量敏感；likelihood 与风险未必天然一致	高	中-大	后期
Trajectory encoder + Survival head	不直接定义几何 Region，而预测 hazard	直接优化 early warning；自然处理 censoring	Region 的几何解释较弱	中	中	建议作为预测头

Mahalanobis 方案与 deep one-class methods 提供了很好的 simple baseline：正常表示可以用 covariance-aware distance 或 hypersphere 描述。

GP state-space model 的优势在于它直接建模 nonlinear transition：

$$z_t = f(z_{t-1}, u_t, c) + \epsilon_t$$

$$f \sim \mathcal{GP}(m, k)$$

于是：

$$p(z_t | z_{t-1}, u_t, c) = \mathcal{N}(\mu_t, \Sigma_t)$$

stable Region 可以直接来自 posterior predictive uncertainty。Variational GP state-space models 本身就是为 nonlinear dynamical systems 建立 tractable posterior 的方法，并通过 sparse approximation 权衡模型容量与计算代价。


HMM/SLDS 可以把 latent stability 分成：

$$S_t \in \{\text{Stable}, \text{Pressure-Responding}, \text{Unstable}\}$$

并让状态转移受 Pressure 控制：

$$P(S_t | S_{t-1}, u_t)$$

这个模型最大的科学价值不是精度，而是它可以直接验证一个非常重要的假设：



也就是你们现在怀疑的：

Pressure response 是一个中间状态，而不是 Drift 本身。

已有动态系统异常检测工作长期使用隐状态模型处理正常与 transient behavior，现代连续时间 HMM 也被用于 trajectory-level temporal state modeling。

Normalizing flow 则可以学：

$$\xi = f_{\theta}(E_{1:t}; c)$$

并利用 change of variables：

$$\log p_{\theta}(E_{1:t} | c) = \log p_0(\xi) + \log \left| \det \frac{\partial f_{\theta}}{\partial E} \right|$$

轨迹异常检测中已经有直接使用 normalizing flow 对 trajectory segments 建模 likelihood，再聚合成 trajectory anomaly score 的工作。

但是我不推荐 flow 作为第一版，因为你们现在最大的未知量并不是：

“stable distribution 是不是 non-Gaussian?”

而是：

“在 matched Persona + Pressure 情况下，stable 和 future-drift trajectory 到底有没有可分辨的 latent dynamics?”

先用 simple model 验证这个假设。

第一版我会真正实现的模型

我会采用：

$$\hat{z}_t^S = g_{\theta}(z_{t-1}, u_t, t, c)$$

其中 g_θ 先用 ridge regression / low-order autoregression。

例如：

$$\hat{z}_t^S = Az_{t-1} + Bu_t + Ct + Dc + b$$

得到 residual：

$$e_t = z_t - \hat{z}_t^S$$

然后使用三轮或五轮 window：

$$E_{t,w} = [e_{t-w+1}, \dots, e_t]$$

计算：

$$A_t = E_{t,w}^\top \Sigma^{-1} E_{t,w}$$

再加 trajectory dynamics：

$$\begin{aligned} A_t^{\text{dyn}} = A_t + \lambda_v \sum_{j=t-w+2}^t \|\Delta e_j\|_2^2 \\ + \lambda_a \sum_{j=t-w+3}^t \|\Delta^2 e_j\|_2^2 \end{aligned}$$

最后 stable Region：

$$\mathcal{R}_{\alpha,t} = \left\{ E_{t,w} : A_t^{\text{dyn}} \leq q_{1-\alpha} \right\}$$

这就是第一版 **Latent Persona Stability Region**。

它非常具体，不再只是一个概念。

评估方案与短期可执行实验计划

最终验证目标不能只是：

“Drift 和 Stable 的最终轨迹能分开。”

那仍然不是 early warning。

必须做 **prefix-only evaluation**。

假设某条 trajectory 的 sustained drift onset 为：

$$T_i$$

在：

$$t < T_i$$

时，只允许使用：

$z_{1:t}, \quad u_{1:t}, \quad \text{text}_{1:t}$

预测：

$T_i \leq t + H$

绝对不能使用 current future probe、未来回答或者最终 trajectory statistics。Gate C 已经建立过这种 causal prefix benchmark，而且明确区分 prospective forecasting 与 contemporaneous detection，这部分设计应该继承，而不是重做一套更容易泄漏的 protocol。

建议继续保留：


$H \in \{3, 5, 10\}$

因为你们已有 Gate C 结果已经说明 forecast horizon 会明显影响结论：development v1 中 activation 对 three-turn、five-turn、ten-turn 的 incremental behavior 并不一致，因此不能只挑一个事后看起来最好的 horizon。

主指标应该包括：

层面	指标	真正回答的问题
Turn-level discrimination	AUROC、AUPRC	未来 H 轮 Drift 与否能否区分
Probability calibration	Brier score	预测概率可信不可信
Event-level	Drift trajectory detection rate	最终发生 Drift 的轨迹有多少提前报出
Specificity	false alarms / 100 eligible turns	稳定轨迹会不会乱报警
Early warning	median / distribution of lead time	能提前几轮发现
Stability geometry	Margin at $T - 10, T - 5, T - 3, T - 1$	是否真正趋近边界
Pressure robustness	Radius vs subsequent outcome	小 Radius 是否预示更高 Drift risk
Cross-axis	resistant-axis pressure false alarm	是否又退化成 Pressure detector
Cross-model	Qwen → OLMo	轨迹规律能否跨模型复现

Gate C 已经证明，同 prefix text 是一个非常强的 comparator：在新 Qwen confirmation 中 TF-IDF text-prefix AUPRC 为 0.9086，而 activation-only 为 0.8048，text+activation 为 0.8966。因此新 Region 方法必须继续与 **same-prefix text baseline** 比较；只证明“activation 自己能预测”不够。最终最希望看到的图应该不是一张 ROC，而是这种 event-aligned trajectory：



Residual						
score	0.10	0.14	0.25	0.52	0.88	1.25
			↑			
			开始偏离	expected stable trajectory		
Margin	+1.40	+1.22	+0.86	+0.41	+0.08	-0.30
					↑	
					Drift 之前已接近 0	
Radius	9.1	7.8	5.2	2.9	0.8	0
					↑	
					只需要极少	additional pressure

同时 Stable trajectory 应该是：

Margin	+1.3	+1.1	+1.2	+0.9	+1.0	+0.8
Radius	8.7	8.1	9.0	7.2	7.8	6.9

→ 有 Pressure Response

→ 但不会持续逼近 Boundary

这张对比图一旦成立，你们的故事就真正起来了。

短期实验计划

我建议不要马上重新生成几千条完整数据。先分成两个阶段。

第一个阶段：完全利用已有 activation logs，验证 “trajectory idea 值不值得继续”。

预计 2-4 个研究日，不包括集群排队。

第一步，导出现有每条 trajectory 的：

$$t, \quad p_t^{(20)}, \quad \Delta p_t, \quad \Delta^2 p_t$$

如有多层 activation，再增加 3-5 个预先固定层，不要在现有 test set 上搜索最佳 layer。

第二步，把四种 condition 分开画：

Neutral

Topic Shift

Gradual Pressure

Abrupt Pressure

并且 Cautious / Independent 分开。

最重要的第一张图就是：

mean Persona Projection ± trajectory bootstrap interval versus Round。

第三步，使用当前多数 stable 的 trajectories 拟合一个非常简单的 conditional expected-response model：

$$\hat{z}_t^S = g(z_{t-1}, u_t, t, \text{persona})$$

不要追求 accuracy。

第四步，画 residual trajectory：

$$e_t = z_t - \hat{z}_t^S$$

看是否出现：

Cautious Future Drift residual $\neq$ Independent Stable Pressure residual

如果连这一步都没有明显差异，就**不要上 GP、flow、HMM**；说明现有 activation 可能根本没有 drift-specific trajectory information。

预期产出是四张图：

1. Raw projection vs turn;
2. Projection slope / acceleration vs turn;
3. Expected Pressure Response vs observed;
4. Residual trajectory aligned to drift onset.

第二个阶段：重新采集 transition-band 数据。

预计约 5-8 个研究日 + HPC queue / generation time。你们现有 240-trajectory Gate A 运行中，generation 与 judge jobs 的单阶段 wall time 大致是小时级，而不是周级，但新的 dose grid 会显著扩大运行数量，所以实际 wall-clock 主要取决于并行资源。

流程是：

这一阶段最少需要留下三个不重叠集合：

Training

用于学习：

g_{θ}, Σ, W

Calibration

用于确定：

$q_{1-\alpha}, \eta$

以及：

Untouched Test

只做一次最终评价。

更严格的话，应该再保留：

整条 unseen Persona axis

作为真正的 cross-axis generalization test。你们自己的 Route A 研究策略已经提出 nested axis/topic splits，并保留至少一个完整 axis 作为 untouched development test；这是非常值得保留的设计。

资料检索与分析的优先级也应该调整。第一优先不是再读大量新论文，而是**原始 trajectory outcome、checkpoint score、每轮 activation 导出和 pressure prompt schedule**；这些决定新的问题是否可识别。第二优先是你们 Gate C v1/v2 的 false-positive rows，尤其 Independent-pressure alarms，它们是构造 pressure-residual model 最有价值的“反例”。第三优先才是 Mahalanobis / one-class、trajectory anomaly detection、GP state-space、HMM、dynamic survival 和 time-series conformal 等原始方法论文，它们负责告诉我们“怎么建模”，但不能替代实验数据告诉我们“有没有可预测信号”。

最终我会把这三个核心概念正式定成下面这组关系：




图 2: transition-band 数据采集与验证流程

Latent Persona Stability Region
 = 在给定 Persona 与 Pressure 历史下,
 Stable trajectories 的条件化接受域

$$M_t = r_{\alpha,t} - \|z_{1:t} - \hat{z}_{1:t}^S\|_{W_t}$$

$$\begin{aligned} \rho_t &= \inf_{\delta u} C(\delta u) \\ \text{s.t. } P(T_{\text{drift}} \leq t + H \mid \mathcal{F}_t, u + \delta u) &\geq \eta \end{aligned}$$

这样三个概念就不会互相重叠：

Region = 正常情况下应该走在哪里

Margin = 现在离正常稳定边界还有多远

Robust Radius = 还需要多少额外 Pressure 才会进入高 Drift 风险

而整篇新的 Seismograph 研究问题也可以被压缩成一句非常清楚的话：

不是检测 Persona activation 有没有移动，而是在相同 Persona 和相同压力条件下，判断它的内部轨迹是否开始偏离“仍能保持人格稳定的正常压力响应轨迹”，并进一步估计距离未来 Drift 边界和所需额外压力还有多远。